Отчёт по контрольной точке 2

Агентный ассистент для проверяемого анализа финансовой отчётности и моделирования торговых решений для бизнеса

9 ноября 2026 года. Учебный проект. Фактическая работа: пользователь и Codex.

Результат этапа

Подготовлен работающий локальный прототип для одного вопроса о выручке группы «ФосАгро» по МСФО. Он находит место прежних доказательств, использует ручную разметку, проверяет контекст и считает изменение программным кодом. Настоящая локальная модель выбирает разрешённые инструменты. Финальный финансовый текст формирует проверяющий код.

Первое сравнение на трёх открытых финансовых шаблонах дало правильный числовой ответ у B и C на 1 из 1 задачи. Корректные отказы: B - 2/2, C - 1/2. При узком поиске агент исчерпал лимит решений. Это малая техническая проверка одного документа, общего качества финансового анализа она не устанавливает. [И1]

Текущий технический архив содержит 205 файлов и восстановлен в новых папках на этом компьютере. В отдельной среде прошли 267 модульных тестов кода. Отдельный обычный запуск настоящего C также завершился. PDF, индекс и модель в архив не входят. [И2]

Задача и границы

Учебная персона - аналитик, которому нужно перепроверить изменение показателя по отчётности. Гипотеза проекта: единый путь от факта к расчёту и объяснимому отказу может упростить такую проверку. Заказчики, интервью, внедрение и экономия времени для бизнеса не подтверждены.

Реализованы один показатель, одна группа, МСФО и два полных года. Приложение принимает фиксированные поля запроса, а не произвольный русский текст. Торговый модуль проверяет отдельный искусственный пример; реальных сделок нет.

Термин	Простой смысл
LLM	Языковая модель, здесь выбирает следующее разрешённое действие
RAG	Ответ с опорой на найденный материал; поиск и качество ответа проверяются отдельно
Агент	Контроллер с моделью, инструментами, наблюдениями и лимитом решений
Fact и Evidence	Факт хранит число с контекстом. Доказательство указывает точное место источника
Эталон и покрытие	Эталон задаёт правильный исход. Покрытие показывает, какие задачи система вообще поддерживает

План и фактическое выполнение

Исходная идея включала анализ отчётности и условное моделирование решения. К КП2 получен узкий проверяемый путь и отдельная искусственная симуляция. Таблица различает готовые компоненты и расширения, которые ещё предстоит сделать.

План	Факт	Проверка	Перенесено	Причина
Документы и факты	Одна версия PDF и два ручных факта выручки	И3, И4	Новые документы и показатели	Нужна проверенная разметка и права
Поиск	Локальный FTS5, оба Evidence нужны для ответа	И1, И5	Автоматическое подтверждение новых чисел	Поиск даёт только кандидатов
Расчёты и ответ	Один калькулятор, версии форматов 0.1, русский CLI	И4, И5	Общий русский QA	Сейчас фиксированный UserQuery
Агентная логика	Настоящий локальный C и отдельный mock	И1, И6	Устойчивое завершение отказа top1	Известный call_limit
Торговый сценарий	Свой synthetic-only пример и реальные запреты	И7	Рыночные цены и исполнение	Неизвестна публикация PDF, нет проверенных рыночных входов
Проверка и интеграция	13 записей, малый замер, восстановленный ZIP	И1, И2, И8	Независимая оценка и перенос на другой ПК	Одна версия и видимые Codex эталоны

Отклонение от дорожной карты

Ранние материалы описывали более широкий корпус, Agentic RAG и проверку условного правила. После КП1 реализация некоторое время не велась; технические компоненты и первые измерения появились в рабочей папке в ноябре. Выполнение шагов 2-13 означает описанный учебный объём, а не готовность всех первоначальных функций.

Старые ориентиры 80% точности чисел, 90% подтверждённости и 80% корректных отказов были предложениями. Они не являются установленными требованиями курса или достигнутыми общерыночными метриками.

Организационные условия

В исторической копии ТЗ для КП2 указаны 5 ноября 2026 года 12:00 и защита 2+1 минуты. На дату отчёта этот срок прошёл. Текущие условия и факт сдачи не подтверждены; срок не переносится задним числом. Подготовленная короткая речь рассчитана примерно на две минуты как рабочая версия.

Архитектура прототипа

Программа получает компанию, границу группы, стандарт, показатель, два года, режим анализа и источник. Неполный или неподдержанный период вызывает уточнение до поиска и модели. Это защищает от молчаливой замены запроса стандартным примером.

Шаг	Что реально происходит
1 Запрос	UserQuery связывает полный 2024 год с полным 2023 и выбранным режимом
2 Поиск	FTS5 проверяет локальные PDF и индекс, возвращает кандидатов с локаторами
3 Проверенные факты	Кандидаты связываются с обоими ранее размеченными Evidence. Текст hit не становится новым фактом
4 Расчёт	Единая функция contracts.answer проверяет совместимость и выполняет annual_growth_v1
5 Ответ	Renderer перепроверяет FinancialToolResult и показывает числа, формулу, ссылки и ограничения

Вариант	Порядок действий	Чем подтверждается результат
B	Фиксированный программный путь	Тот же реестр, поиск, калькулятор и модуль отображения
C с моделью	Qwen3 4B выбирает действие по наблюдениям	Те же инструменты плюс контроллер, история и лимиты
C mock	Детерминированная имитация действий	Техническая проверка протокола, не качество LLM

Доверенные границы

Контроллер разрешает search_evidence, get_verified_fact, calculate_growth и finish. Код проверяет ID, версии, режим, порядок и зависимости. Свободный Python, shell, eval и брокерские операции не исполняются. Документ и вывод модели являются недоверенными данными.

C ограничен шестью решениями, включая ошибки, повторы и finish, 180 секундами на случай, 90 секундами на ожидание и 256 выходными токенами на решение. Контекст 8192, temperature 0, think=false. Это инженерные пределы, не измеренный оптимум. [И6]

Финансовые статусы answered, missing, conflict и unsupported отделены от технической ошибки, уточнения и состояния исполнения агента. Call_limit или timeout не становятся корректным финансовым missing.

Источник и проверяемый расчёт

Источник - консолидированная отчётность группы «ФосАгро» по МСФО, выбранная версия годового отчёта 2024. Значение за 2023 год взято из сравнительного столбца этой же версии, а не из первоначальной публикации 2023. [И3, И4]

Показатель	Полный период	Значение	Единица
Выручка	01.01.2023-31.12.2023	440 304	млн RUB
Выручка	01.01.2024-31.12.2024	507 689	млн RUB
Изменение	2024 к 2023	+67 385	млн RUB

$$\text{Рост} = \left(\frac{507689}{440304} - 1\right) \times 100\% = 15{,}30\%$$

Код использует Decimal с точностью 50 значащих цифр, отображает процент с двумя знаками HALF_UP. Дополнительные внутренние знаки не повышают точность опубликованных округлённых сумм. Независимый контроль эталона использовал Fraction и буквальные проверки.

Точный локатор

PDF-страница 4, левая половина разворота, печатная страница 320, страница формы 1. Таблица прибыли или убытка и прочего совокупного дохода, строка «Выручка», примечание 6, колонки 2024 и 2023, заголовок «Млн руб.». Исходные 507,689 и 440,304 положительные; запятая разделяет тысячи.

Первичный PDF с переходом на страницу 4

Страница финансовой отчётности эмитента

Версия: 1 521 928 байт, 23 страницы, SHA-256:

`824f100d14396c26faacf80a03cca6b20d458c9b5d835201bc80068decb3d6e1`

Ограничения источника

Публикация именно этой PDF-версии неизвестна и не доказана. Подпись 13.02.2025, время получения, CreationDate, конец периода и дата другого ZIP её не заменяют. Snapshot анализирует выбранную полученную версию; historical не выдаёт число без подтверждённой доступности.

Сохраняются аудиторская оговорка о раскрытии сегментов по IFRS 8, статус ручной разметки assistant_checked и неизвестные права на распространение копии. Семантическая визуальная сверка записана на шаге 11; в шагах 12-14 новая сверка PDF не заявляется. Полные страницы и текст остаются в исключённой tmp/.

Проверочные вопросы и протокол

Набор kp2-question-set-v1 версии 1.0.0, схема 0.1, заморожен до измерений. Он содержит 13 записей с контекстом, исходами, локаторами, единицами, округлением, происхождением и хешами. [И8]

Раздел	Количество	Доступный маршрут
Финансовые вопросы	10	3 у B/C, 2 только finance API, 5 требуют адаптера
Интерфейсное уточнение	1	B и C-вход, до модели
Искусственные сценарии	2	Отдельный simulator

9 записей имеют контекст реального источника, 4 являются собственными искусственными. Реальная часть основана на одном PDF и двух фактах. 9 случаев открыты для разработки; QA04, QA05, QA08 и SC02 зарезервированы. Codex создавал и видит эталоны, исходные данные использовались при разработке. Слепая независимая проверка не заявлена.

У B/C поддержаны QA03 (расчёт), QA06 (исторический отказ) и QA07 (недостаточная выдача top1). Все три открытые, числовая задача одна. В резервной финансовой части поддержанных B/C-задач нет: метрика не измерена, n=0. Прямой факт, иной масштаб, первоначальная версия 2023 и ложная предпосылка не подменяются стандартным расчётом роста.

Два сохранённых прохода

До ответов сохранены порядок, входы, хеши кода, данных, инструкции моделиа, модели и лимиты. В run-01 сервер из песочницы не читал model manifest: Access is denied, tags пуст. B и компоненты сработали, C остановился до генераций, chat=0. Неудачи сохранены.

После разрешённого запуска того же сервера вне песочницы отдельный run-02-environment-retry повторил тот же один проход. Код, инструкции модели, модель, лимиты, входы и gold не менялись. Разогрева chat не было. SC02 уже открылся в первом проходе и не настраивался.

Как считается результат

Строгий успех требует правильные число, группу, стандарт, показатель, полные периоды, единицы, версию, режим, формулу и оба Evidence. Пропуски фактического результата не дописываются эталоном. Числитель показывает успешные случаи, знаменатель - заранее выбранные подходящие задачи. Сбой остаётся в знаменателе.

Отказы, интерфейс, сценарии и поиск считаются отдельно. Четыре числовых утверждения QA03 - две суммы, разность и процент. Формула и повторная подстановка проверяются как обоснование. Отсутствие утверждений или случаев означает неприменимость, а не 100%. Оценщик проверяет структурированный результат и узкий штатный модуль отображения, не произвольный свободный текст.

Результаты первых измерений

Метрика run-02	B	C с Qwen3 4B
Строгий числовой вопрос QA03	1/1	1/1
Корректные отказы QA06 и QA07	2/2	1/2
Подтверждённые числовые утверждения QA03	4/4	4/4
Ложные отказы на QA03	0/1	0/1
Покрытие финансовых вопросов	3/10	3/10
Финансовые вопросы резерва	Не измерено n=0	Не измерено n=0

QA03 у обоих дал исходные суммы, изменение и процент с контекстом и ссылками. QA06 у обоих завершился missing/publication_unknown. На QA07 B корректно отказал, а C вернул limit_exceeded/error/call_limit. [И1]

Случай	B секунды	C секунды	C chat	Вход токены	Выход токены
QA03	0,004450	14,971038	5	19 120	268
QA06	0,002349	7,043395	6	8 746	302
QA07	0,003743	6,802761	6	11 134	279

Что произошло на top1

После поиска и двух недоступных фактов агент дважды повторил тот же поиск (repeat_call). На шестом решении калькулятор вернул правильный missing, но не осталось вызова finish. Пользователю не показано неверное число, однако финансовый отказ не завершён. Это ошибка, не успех. Эталон и лимит под неё не изменялись.

Один уникальный поисковый запрос «выручка 2024 2023» при k1 покрывает 0/2 Evidence, при k5 - 2/2. Оба Evidence находятся в одном фрагменте PDF4 слева на ранге 2. Повтор этого query в разных вопросах не создаёт независимые поисковые задачи.

Время и стоимость

В run-02 было 17 настоящих chat-запросов и 17 ответов, 39 000 входных и 849 выходных токенов. Первый C включает холодную загрузку 5,4241429 секунды; старт сервера вне времени ответа. Единичные замеры не устанавливают устойчивую скорость, медиану, p95 или превосходство. API-платежей нет, общая денежная себестоимость, электричество и оборудование не измерены.

UI01 отдельно: 1/1 у B и C-входа, C без chat. QA09/10 отдельно: finance API 2/2. SC01/02 отдельно: simulator 2/2. Ни один из этих результатов не прибавляется к числовому знаменателю QA03.

Искусственный виртуальный сценарий

Собственный искусственный набор использует вымышленные группу, даты, календарь и цены. Правило заранее зафиксировано: рост выручки строго больше 10%, капитал 10 000 RUB, номинал до 20% без комиссии, лот 1, комиссия 1 RUB на сторону, базовое проскальзывание 0. Модель не выбирает сделки. [И7]

Событие	Расчёт	Деньги после	Позиция
Начало	Капитал	10 000 RUB	0
Покупка	20 × 100 + комиссия 1	7 999 RUB	20
Продажа	20 × 105 - комиссия 1	10 098 RUB	0

Итог +98 RUB, или +0,98%, комиссии 2 RUB. Удержание той же доли, окна, цен и расходов дало тот же итог; преимущества правила не установлено. Деньги без процентов остаются 10 000 RUB. Это контроль арифметики, не доходность реального рынка.

Временная логика

Учебная публикация 04.06.2025 в 19:00 +03, решение в 19:30 после закрытия. Покупка 05.06 в 10:00 строго после решения, продажа 09.06 в 18:00. Требуются точные цены, известные календарь и доступность фактов. Период отчёта не заменяет публикацию. Проскальзывание уже включено в цену, повторно не вычитается.

Пропуск цены, неподдержанное корпоративное событие, несовместимая валюта, недостаток денег или нулевой лот приводят к запрету без частичных сделок и доходности. Реальный календарь, ликвидность и брокер не реализованы.

Вариант расходов и настоящий запрет

SC02 создан отдельно: доля 20,5%, комиссия 3 RUB на сторону, проскальзывание 50 б.п. Количество 20, цены исполнения 100,5 и 104,475, деньги после покупки 7 987, итог 10 073,50 RUB, комиссии 6, процент 0,74. Его эталон проверен Fraction и целочисленным журналом, а затем программным симулятором как отдельный компонент.

Настоящий источник остаётся blocked/publication_unknown без сделок и return. Старый Answer.scenario_gate сохраняет прежний blocked-placeholder; отдельная synthetic-only оболочка его не превращает в допуск реальной торговли. В CLI оба режима выбираются явно.

Восстановление и инструкция запуска

Текущий технический пакет: delivery/kp2-local-step13-v1-2026-11-09.zip. Его размер 559 580 байт, 205 файлов полезного содержимого и один внутренний manifest. Отдельный receipt фиксирует SHA и проверку. Старые ZIPv2/v1 сохранены как история шагов 2-5. [И2]

```
SHA-256 ZIP
10920fd2e55614eb6c06b28f4499e55d4f0b58bf2d7156a7f6eaa3199ed4efec
```

Пакет распакован в новые папки на том же компьютере. Использован отдельный venv без pip, MSYS2 CPython 3.14.7, isolated Python (-I). Прошли 267 модульных тестов кода (255 прежних + 12 архива), 8 минимальных и 4 поисковых интеграционных случая, 8 проверок границ CLI. Итоговый выдаваемый ZIP отдельно восстановлен и прошёл 8+4 проверки. Это технические проверки кода, не дополнительные вопросы качества.

Отдельный настоящий обычный запуск C из восстановленного кода завершился за 5 решений, 19 120/268 токенов и 14,611095 секунды всего CLI. Модель использовалась прежняя из исходного корня на этом компьютере, клиент - из восстановленного. Это проверка интеграции, не новый benchmark и не установка модели с нуля на другом ПК. Сервер после проверки остановлен.

Минимальные команды из корня новой копии

```
python -I scripts/run_local.py fixed --source manual

python -I scripts/run_local.py scenario

python -I scripts/run_local.py agent --adapter mock --source manual
```

Manual явно использует прежнюю разметку без текущей проверки PDF/поиска. Scenario явно вымышленный. Mock является имитацией, настоящая LLM не подставляется автоматически. Полная инструкция проверки ZIP и восстановления - docs/local_demo.md.

Зависимости и найденные ошибки

Для search нужны совпадающие PDF и индекс только в личной tmp/. Для C/LLM отдельно нужен прежний локальный сервер выбранной версии Ollama 0.40.15/qwen3:4b, порт 11435, облако отключено. Весов, бинарников, PDF, страниц и полного текста в пакете нет.

Сохранены реальные ошибки восстановления: соседний импорт assistant при -I, MSYS2 bin вместо Scripts для venv, отсутствие пустой tmp/ у старого теста и кодировка неизвестного режима новой оболочки. Исправлены launcher и создание рабочей tmp/, пути описаны. Финансовое ядро, старые тесты, замороженные вопросы и прежние доказательства сохранены. Неудачи не удалялись.

Риски и дальнейшие задачи

Риск или ограничение	Текущее последствие	Следующее действие
Один PDF и один показатель	Малый зависимый набор не проверяет перенос	Подготовить проверяемые источники и отдельный корпус
Неизвестна публикация версии	Исторический числовой ответ и реальная торговля запрещены	Доказать связь версии с временем публикации
Неустановленные права	PDF и полный текст не распространяются	Сверить условия до расширения корпуса
C не завершает top1	1/2 корректных отказов в малом замере	Отдельно исправлять завершение отказа с сохранением версии
Ручная разметка и видимые эталоны	Автоматическое извлечение и слепая оценка не доказаны	Добавить новые задачи и независимую проверку
Локальная модель и среда	Другой ПК и установка с нуля не проверены	Отдельно проверить разрешённое развёртывание

Самооценка готовности

Учебный сквозной путь, объяснимые ограничения, независимая арифметика эталонов и восстановленный пакет подтверждены артефактами. Надёжность общего финансового анализа, полезность для бизнеса, перенос на новые компании и рыночное моделирование не установлены. Тесты защищают договоры кода, но не заменяют эти исследования. Оценка преподавателя не прогнозируется.

Фактический вклад

Кто	Подтверждённая работа
Пользователь	Выбрал направление, одиночный рабочий режим, локальный путь и модель; принимал существенные решения и разрешал действия
Codex	Реализовал компоненты, подготовил ручную разметку и свои искусственные наборы, сверил источники, выполнил расчёты, тесты, измерения, сборку и эти материалы

Пять именных ролей сохранены только для регламента. Им не приписываются разработка, независимая приёмка или подписи. Assistant_checked не означает human_reviewed. Отдельная техническая сверка двумя способами не создаёт двух людей.

Ближайший организационный шаг - сверить актуальные требования и способ сдачи, затем отдельно отправить готовый пакет с реальной квитанцией. Этот отчёт не является подтверждением отправки.

Проверяемые артефакты

Все пути ниже относительны корню рабочей папки. Их файлы и хеши позволяют связать утверждение с версией кода и данных. Локальные пути не являются публичной ссылкой на репозиторий.

И1 Первые измерения

```
evaluation/step12_2026-11-09/run-02-environment-retry/results.json
```

И1 Первый неудачный проход

```
evaluation/step12_2026-11-09/run-01/results.json
```

И2 Архив и восстановление

```
delivery/kp2-local-step13-v1-2026-11-09.receipt.json
```

И2 Интеграционная проверка

```
evaluation/step13_2026-11-09/report.json
```

И3 Семантическая сверка PDF

```
evaluation/step11_2026-11-09/source-verification.json
```

И4 Минимальная разметка

```
data/examples/reference_bundle.json
```

И5 Калькулятор и поиск

```
src/financial_assistant/contracts.py
src/financial_assistant/finance.py
src/financial_assistant/retrieval.py
```

И6 Контроллер и локальная модель

```
src/financial_assistant/agent.py
data/config/local_model.json
```

И7 Собственный сценарий и контроль

```
data/synthetic/scenario_v1.json
evaluation/step11_2026-11-09/independent-controls.json
```

И8 Вопросы и заморозка

```
data/question_sets/kp2_v1/questions.json
data/question_sets/kp2_v1/manifest.json
```

Независимая воспроизводимость: scripts/measure_step12.py replay пересчитывает метрики по сохранённым raw/gold без модели, поиска и production-решения задач. Guarded replay дополнительно запрещал socket и импорт ответчика. Полная методика и ограничения - docs/measurements.md.

T²-RAGBench использован как методический принцип раздельной оценки поиска и ответа на одинаковых данных. Его набор не скачивался и не запускался; внешние метрики и перенос на российские источники не заявлены.